

Análisis Exploratorio de Datos con R



Enfoque Metodológico

- ✓ R como herramienta de investigación, no como un fin en sí mismo.
- ✓ Desmitifica la programación para investigadores empíricos.
- ✓ El EDA es el primer apretón de manos con nuestra evidencia.

¿Por qué hablar de EDA en un curso de diseño experimental?

Relevancia del EDA

01 — Calidad de datos e inferencias

La calidad de los datos determina directamente la calidad de las inferencias estadísticas. Sin una exploración previa, incluso las pruebas más sofisticadas pueden producir conclusiones erróneas o engañosas.


02 — Exploración y decisiones metodológicas

El EDA vincula la exploración con decisiones metodológicas fundamentadas. Antes de elegir una prueba estadística, es necesario conocer las propiedades de los datos que se analizarán.

03 — Investigación aplicada rigurosa

En investigación aplicada, los datos suelen ser complejos, incompletos y heterogéneos. Explorar antes de analizar es una práctica científica rigurosa, no un paso opcional.

Flujo de Trabajo EDA



Que es EDA?

Definición

Conjunto de técnicas para **examinar, resumir y visualizar** datos antes de aplicar modelos estadísticos formales. Fue sistematizado por **John Tukey** en los años 1970 como enfoque para "dejar que los datos hablen".

Objetivos

Comprender la **estructura** de los datos, detectar **patrones**, identificar **anomalías** y orientar el análisis posterior. Responde: ¿Qué dicen los datos? ¿Qué problemas tienen? ¿Qué análisis son apropiados?

Explorar, Describir, Inferir Inferir

Tres etapas **complementarias pero distintas**: explorar (descubrir), describir (resumir) e inferir (generalizar). El EDA se enfoca en las dos primeras como paso previo indispensable a la inferencia.

Qué es el Análisis Exploratorio de Datos (EDA)

Conjunto de técnicas estadísticas para la exploración preliminar, diagnóstico de calidad y comprensión profunda de los datos empíricos antes del modelado.

1 Recolectar Datos

Recopilación de la información bruta, evaluando su origen y diseño de recogida.

4 Visualizar

Aplicación de métodos gráficos y descriptivos para evaluar la distribución univariada y explorar relaciones bivariadas preliminares entre variables.

2 Inspeccionar

Examen de la estructura de los datos para identificar errores de codificación, inconsistencias y comprender la naturaleza de las variables.

3 Limpiar

Procesamiento y tratamiento sistemático de valores ausentes (NA) y detección de valores atípicos (outliers) para asegurar la calidad de los datos.



El EDA no busca probar hipótesis, sino asegurar la validez interna y la consistencia de los datos empíricos como paso previo indispensable al análisis confirmatorio.

¿Para qué sirve el EDA antes del análisis formal?

Funciones del EDA

01 — Conocer la estructura

Permite conocer las **variables, tipos, dimensiones y organización** de la base de datos antes de cualquier análisis.

02 — Detectar errores y patrones

Detecta **errores de codificación, valores imposibles, inconsistencias** y revela patrones ocultos como tendencias, agrupaciones y asociaciones.

03 — Identificar anomalías

Identifica **datos atípicos (outliers)** que pueden distorsionar modelos estadísticos, y documenta **datos faltantes** que afectan la interpretación.

04 — Apoyar decisiones analíticas

Apoya **decisiones analíticas posteriores**: elección de pruebas, transformaciones de variables y selección de modelos apropiados.

Del Hallazgo a la Decisión Metodológica

El EDA no es un trámite, es un ejercicio de rigor científico.

Hallazgo Técnico en EDA	Decisión Metodológica del Investigador
Distribución fuertemente asimétrica.	Usar estadística no paramétrica.
Alta tasa de no respuesta en una variable.	Decidir: ¿Imputar, excluir o analizar sesgo?
Baja frecuencia en respuestas específicas.	Agrupar o recodificar variables.



¿Por qué usar R y RStudio?

Software libre

Gratuito y accesible para todo estudiante e investigador sin barreras económicas. Además, cuenta con una **comunidad académica amplia** con recursos educativos y literatura científica disponible.


Reproducibilidad

Los **scripts** documentan cada paso del análisis, permitiendo replicar resultados. El trabajo con sintaxis genera **transparencia**: el código explicita las decisiones tomadas en cada etapa.

Flexibilidad y control control

Miles de paquetes especializados para todo tipo de análisis estadístico. A diferencia del software de menús, en R el investigador tiene **control total** sobre cada paso del análisis.

Flujo de Trabajo en R



Datos Tidy

pais	anio	tipo	casos	pais	anio	casos	poblacion
Afganistán	1999	casos	745	Afganistán	1999	745	19987071
Afganistán	1999	población	19987071	Afganistán	2000	2666	20595360
Afganistán	2000	casos	2666	Brasil	1999	37737	172006362
Afganistán	2000	población	20595360	Brasil	2000	80488	17504898
Brasil	1999	casos	37737	China	1999	212258	1272915272
Brasil	1999	población	172006362	China	2000	213766	1280428583
Brasil	2000	casos	80488				
Brasil	2000	población	174504898				
China	1999	casos	212258				
China	1999	población	1272915272				
China	2000	casos	213766				
China	2000	población	1280428583				

Tabla 2

Fundamentos para la Implementación de R como Herramienta de Análisis

La importancia de la replicabilidad y el control metodológico en la investigación científica



1. Replicabilidad Científica: Permite la auditoría y reproducción exacta de los análisis, una exigencia fundamental en la investigación académica.



2. Control Metodológico: Permite definir explícitamente cada paso del análisis, evitando configuraciones "por defecto" ocultas.



3. Innovación y Accesibilidad: Software de código abierto en constante actualización, con acceso temprano a nuevas técnicas estadísticas.



4. Eficiencia Operativa: Incremento exponencial de la eficacia en el manejo de grandes volúmenes de datos y tareas repetitivas.

Software Comercial Basado en Menús



1. Opacidad Analítica: La interfaz gráfica oculta la lógica computacional subyacente, dificultando la comprensión profunda del proceso.



2. Barreras de Acceso: Dependencia de licencias comerciales, limitando la accesibilidad y la colaboración interinstitucional.



3. Limitaciones en la Replicación: Dificultad para auditar y reproducir exactamente la secuencia de procedimientos realizados mediante menús.



4. Ineficiencia y Riesgo de Error: Procedimientos manuales repetitivos que aumentan la probabilidad de errores y reducen la eficiencia en análisis complejos.

Primer acercamiento a R y RStudio

El entorno de trabajo

01 — R y RStudio

Res un lenguaje de programación estadística. **RStudio** es un entorno de desarrollo integrado (IDE) que facilita el trabajo con R.

02 — Consola y Script

La **consola** ejecuta comandos con resultados inmediatos. El **script** es un archivo de texto donde se escribe y guarda el código para reproducir el análisis.

03 — Entorno y paneles


El **entorno (Environment)** muestra los objetos creados. Los paneles de **archivos, gráficos y paquetes** permiten navegar carpetas, visualizar figuras y gestionar librerías.

04 — Principio clave

No es necesario **memorizar todo**: el objetivo es comprender la lógica del análisis, no aprenderse los comandos de memoria.

El Motor y el Tablero: R y RStudio

Desmitificando la interfaz de usuario.



R: El Motor

El lenguaje de programación subyacente que procesa la información.



RStudio: El Tablero (IDE)


La interfaz amigable para manejar el motor sin ser ingeniero mecánico.

1. Script (Editor)



Escribir la receta aquí.
Su cuaderno de notas auditable.

3. Entorno (Environment)



Ver datos vivos aquí.
Memoria temporal y objetos cargados.

2. Consola



Ver resultados del motor aquí.
Donde se ejecutan las órdenes.

4. Plots / Ayuda



Ver gráficos y mapas aquí.



Fundamentos mínimos de R para comenzar

Objetos y vectores

En R todo se almacena en **objetos** mediante asignación (<-). Los **vectores** son secuencias de valores del mismo tipo, la unidad básica de datos en R.

Data frames

Estructuras tabulares donde filas = **casos** y **columnas** = **variables**, similares a una hoja de cálculo. Son el formato más común para bases de datos en R.

Tipos de variables

Numéricas (continuas), **enteras**, **caracteres** (texto) y **factores** (categóricas). Leer un archivo, inspeccionar su estructura y obtener un resumen general son los primeros pasos.

Primeros pasos al abrir una base de datos

Inspección inicial

01 — Dimensiones y estructura

¿Cuántas **filas y columnas** tiene? ¿Qué representa cada fila? ¿Cuánta memoria ocupa la base de datos?

02 — Nombres y tipos de variables

Revisar que los **nombres sean claros y consistentes**. Verificar que las variables numéricas se lean como números y las categóricas como factores.

03 — Primeras comprobaciones


Revisar **rangos de valores, categorías esperadas y formatos**. Nunca confíes ciegamente en los datos: verifica siempre lo que recibes.

Principio fundamental: la calidad del análisis depende de la calidad de la inspección inicial

Fundamentos del Lenguaje: Cajas y Acciones


La programación orientada a objetos en R.

Objetos
(La Caja)



Asignación

Funciones (El Verbo)




```
edad_sujetos <- c(25, 30, 45, 28)
mean(edad_sujetos)
```

Data Types




Data Frames:
La base de datos
(Filas=Casos,
Columnas=Variables).



Numeric:
Números continuos
(ej. Edad).



Character:
Texto (ej.
Nombres).



Factor:
Variables
categóricas (ej.
Nivel
Socioeconómico).

Componentes centrales del EDA

Estructura y descripción

Revisión de estructura: dimensiones, tipos de variables, nombres y organización. **Análisis descriptivo:** medidas de tendencia central, dispersión y distribución de frecuencias.

Distribución y valores extremos

Análisis de la **forma**, **simetría**, moda y **rangos** de las variables. **Detección de valores extremos (outliers):** identificación y evaluación de su impacto en el análisis.

Datos faltantes y consistencia

Identificación de datos faltantes: frecuencia, patrón y mecanismo de ausencia. **Evaluación de consistencia:** coherencia entre variables y reglas de validación lógica.

Estadística descriptiva como parte del EDA

Medidas descriptivas

01 — Frecuencias y porcentajes

Para **variables categóricas**, muestran la distribución de casos entre las diferentes categorías. Permiten identificar categorías dominantes o raras.

02 — Media y mediana

La **media** es el valor promedio, útil con distribuciones simétricas. La **mediana** es el valor central, más robusta cuando existen valores extremos.

03 — Dispersión y rango

La **desviación estándar** mide la dispersión alrededor de la media. El **rango** (mínimo y máximo) delimita el intervalo de valores observados.

La interpretación siempre debe hacerse en contexto: los números cobran sentido en la pregunta de investigación

El Checklist Central del EDA

La hoja de ruta metodológica al enfrentar una nueva base empírica.



Ajuste de Tipos de Variables.

Asegurar que las categorías (1=Hombre, 2=Mujer) se lean como factores, no como matemáticas.




Detección de Datos Faltantes (NA).

Cuantificar la “no respuesta” o pérdida experimental.



Identificación de Valores Atípicos (Outliers).

Encontrar valores extremos o improbables que distorsionan los promedios (ej. 999 años).



Comportamiento Descriptivo.

Mirar la concentración, forma y varianza.

Paso obligatorio
antes de aplicar
cualquier modelo
de inferencia
estadística.

Estadística Descriptiva con un Solo Comando

Sintetizando la muestra matemática y socialmente.

Concepto Estadístico	Función en R
Centro: Media y Mediana (El centro de gravedad).	<code>mean()</code> , <code>median()</code>
Dispersión: Desviación Estándar y Rango (Heterogeneidad).	<code>sd()</code> , <code>range()</code>
Frecuencias: Para variables categóricas.	<code>table()</code>



La **Navaja Suiza**: Resume miles de filas entregando mínimos, cuartiles, mediana, media y máximos en una sola instrucción.

```
summary(mis_datos$ingreso)
```

```
table(mis_datos$grupo_tratamiento)
```


DATA VISUALIZATION

Visualización de datos

Histogramas y boxplots

Los **histogramas** muestran la distribución de una variable numérica: forma, simetría y modas. Los **boxplots** resumen mediana, cuartiles y valores atípicos en una sola figura.

Barras y dispersión

Los **gráficos de barras** comparan frecuencias entre categorías. Los **diagramas de dispersión** revelan relaciones entre dos variables numéricas.


El poder de la visualización visualización

La visualización permite **detectar patrones, anomalías y relaciones** que los números solos no revelan. Un buen gráfico es **herramienta de pensamiento**, no solo de presentación.

El Poder Exploratorio de la Visualización

El cerebro detecta patrones en gráficos mucho mejor que en tablas de números.


Forma de la Distribución



Histograma: Revela la asimetría y el comportamiento general de la muestra continua.

```
hist(mis_datos$edad)
```

Detección de Outliers



Boxplot: La herramienta reina para comparar grupos y detectar anomalías extremas.

```
boxplot(mis_datos$ingreso ~ mis_datos$tratamiento)
```

Datos faltantes y calidad de datos

Gestión de ausencias

01 — ¿Qué son y por qué importan?

Valores ausentes por **errores, omisiones o respuestas no válidas**. Pueden **sesgar resultados**, reducir potencia estadística y limitar análisis.

02 — Detección y patrones

Identificar **cuántos valores faltan, en qué variables** y si hay patrones sistemáticos. Las estrategias de manejo dependen del mecanismo de ausencia.

03 — Decisiones posibles

Eliminación de casos, imputación de valores, análisis separados o modelos que toleran ausencias. La elección depende del patrón y del mecanismo.

Regla de oro: documentar siempre qué se hizo con los datos faltantes y por qué

Ejemplo práctico introductorio en R

Dataset: iris

01 — Cargar y explorar

El dataset **iris** (incluido en R) contiene 150 flores con medidas de sépalo y pétalo para 3 especies. Usar **dim()**, **str()**, **head()** para explorar.

02 — Resumen descriptivo

Aplicar **summary()** para obtener un resumen descriptivo básico de todas las variables: mínimo, máximo, media, mediana y cuartiles.

03 — Visualizar y detectar

Crear un **histograma** de una variable numérica y un **boxplot** para identificar especies con medidas atípicas. Código corto, comentado y explicado paso a paso.

El código es corto, comentado y acompañado de explicación conceptual paso a paso

Buenas prácticas para trabajar en clase

Guardar y documentar

Guardar scripts: cada sesión debe quedar documentada en un archivo reproducible. **Documentar decisiones:** anotar por qué se excluyeron casos o transformaron variables.

Organizar y revisar

Organizar archivos: separar datos brutos, datos procesados, scripts y resultados en carpetas claras. **Revisar críticamente:** los números no son neutrales.


Reproducibilidad

Garantizar reproducibilidad: otro investigador debe poder llegar a los mismos resultados con los mismos datos y código. El trabajo analítico responsable es tan importante como el conocimiento técnico.

Ejemplo Práctico: El EDA Salva la Investigación

Flujo de trabajo para detectar tabulaciones incorrectas.

Script Editor (Simulado)



```
1 # 1. Inspección de estructura
2 str(encuesta)
3
4 # 2. Resumen descriptivo rápido
5 summary(encuesta$edad)
6
7 # 3. Visualización diagnóstica
8 hist(encuesta$edad)
```

Consola y Gráficos (Salida Simulada)


Consola

```
> summary(encuesta$edad)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
18.0	25.0	34.0	45.2	55.0	999.0

Error de código:
¡No Responde!


Histogram of encuesta\$edad



Si pasamos estos datos a un modelo
sin EDA, la regresión sería absurda.

Reglas de Oro del Laboratorio de Datos

El código es documentación científica para consumo humano.




Cero alteraciones al original:

El Excel matriz queda intacto. RStudio es el único lugar donde se **manipula y limpia** mediante código.



Comentar intensivamente:

Usar el símbolo # para explicar el **porqué metodológico** de una decisión, no solo qué hace la máquina. Su 'Yo' del futuro lo agradecerá.



Anclaje Teórico:

Ningún tratamiento de *outliers* o NA se hace por **capricho estadístico**; requiere estricta justificación teórica.

```
# Excluimos edad 999 por ser error de codificación según el manual  
encuesta_limpia <- encuesta[encuesta$edad < 100, ]
```

REG. 3

REG. 2

REG. 1

REG. 3

REG. 3

CÓDIGO EJEMPLO

Conclusiones: El Respeto por la Evidencia

El análisis estadístico no reemplaza el criterio del investigador; lo potencia.

Garantía de Validez: El EDA asegura la integridad y robustez del diseño experimental.

Respeto Empírico: Explorar los datos es el respeto que le debemos al esfuerzo de recolección en campo.



Transparencia Científica: R maximiza la reproducibilidad; no memorice comandos, entienda la lógica del flujo.